

Trabalho Prático 1

Séries Temporais - 1/2023


Carolina Musso 18/0047850

Gabriela Carneiro de Almeida 18/0120816

Renan Menezes de Araujo

Introdução


A pesquisa “Manufacturers’ shipments, paper and allied products” (M3) fornece dados estatísticos mensais sobre as condições econômicas no setor de manufatura doméstica (empresas pequenas). A pesquisa mensura a atividade industrial atual e fornece uma indicação das tendências futuras desses tipos de negócios.



```
[1] "Manufacturers' shipments, paper and allied products"
```


```
[1] "Passenger cars, from Canada (new), imports (complete units)"
```

a. Decomposição da série temporal via STL (ou MSTL).



Primeiramente a função `stl()` - “Seasonal an trending using Loess”- foi utilizada para decompor a série analisada. Como pode ser observado no gráfico, há uma tendencia crescente ao longo do tempo analisado e há, também, uma sazonalidade na série. Porém, a análise de resíduos mostra, aparentemente, que a decomposição utilizada não foi capaz de decompor a sazonalidade de uma maneira eficiente, já que ainda há indícios dessa sazonalidade nos resíduos.


Uma alternativa é utilizar a função de decomposição `mstl()`, que é uma versão automatizada. Essa função é capaz de identificar multiplas sazonalidades.



O gráfico da decomposição MSTL é bem parecido com o gráfico obtido na decomposição STL, indicando que não há múltiplas sazonalidades. Ainda assim, os resíduos não parecem aleatorizados.

b. Escolha um modelo ARIMA adequado de forma manual.


- Série “Manufacturers’ shipments, paper and allied products”



Número de diferenciações simples (d)	Número de diferenciações sazonais (D)
1	1

Conforme observado na tabela acima, a série se torna estacionária com um diferenciação simples e necessita, também, de uma diferenciação sazonal, seguindo um modelo

$$SARIMA(p, 1, q)X(P, 1, Q)$$



$p = 0$, $q = 0$, $AICc = 1242.927$

$p = 0$, $q = 1$, $AICc = 1159.533$

$p = 0$, $q = 2$, $AICc = 1144.458$

Melhor configuração do modelo seria:

$SARIMA(2, 1, 1)X(1, 1, 1)$

Series: dados

ARIMA(0,1,2)(0,1,1)[12]

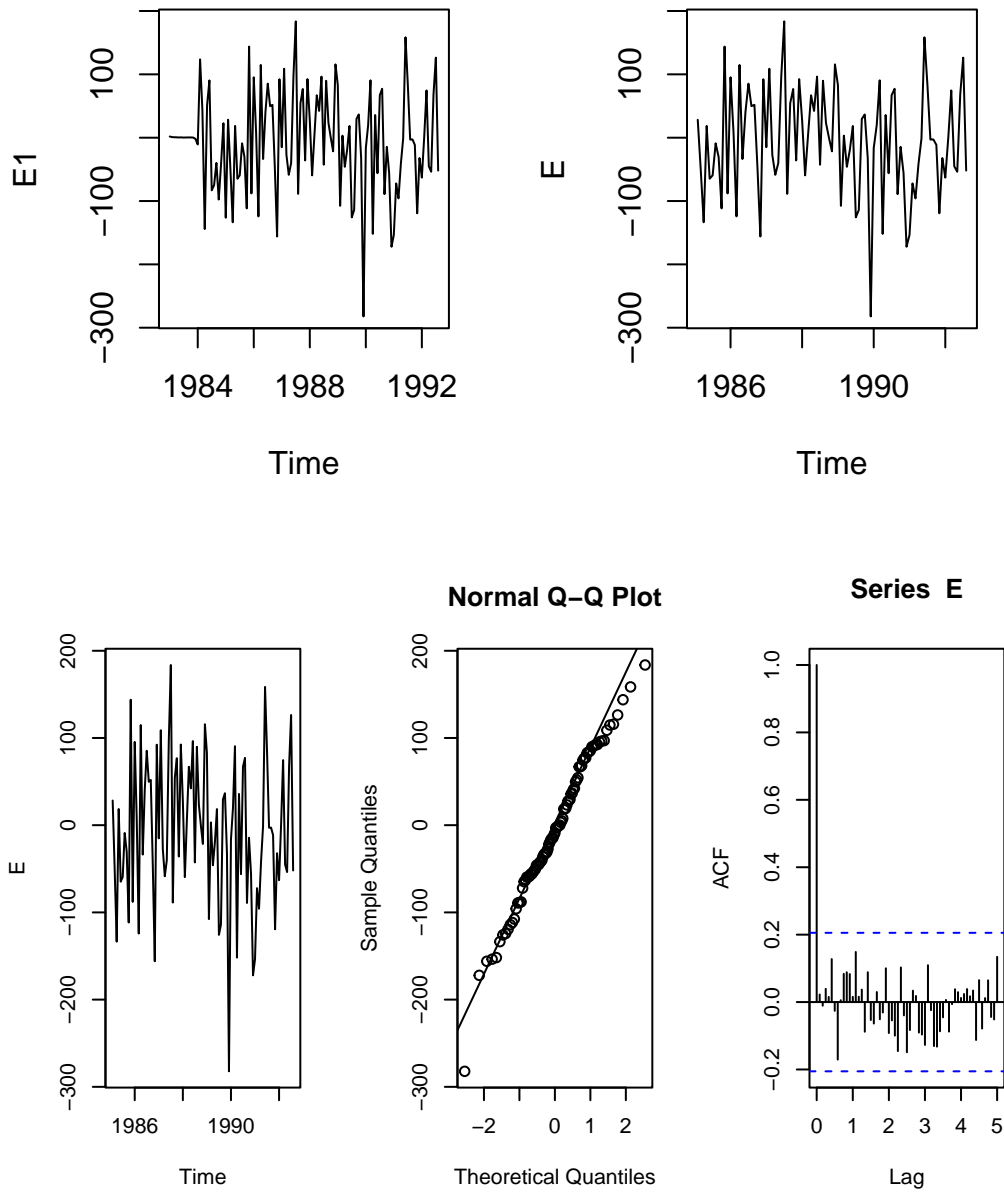
Coefficients:

	ma1	ma2	sma1
	-0.3468	0.1799	-0.7813
s.e.	0.1095	0.0985	0.1238

$\sigma^2 = 7275$: log likelihood = -608.25

AIC=1224.49 AICc=1224.9 BIC=1235.03

c. Análise de resíduos do modelo selecionado.



Teste KPSS - estacionariedade	Teste Box-Ljung - independência	Teste Shapiro-Wilk - normalidade
0.1	0.837631	0.5106649

O modelo ajustado cumpre os pré-requisitos de estacionariedade, independência e normalidade, indicando que é um modelo que pode explicar a série.

d. Comparando o modelo obtido com a função `auto.arima`

Series: dados

ARIMA(0,1,3)(0,1,1)[12]

Coefficients:

	ma1	ma2	ma3	sma1
	-0.3485	0.1070	0.1906	-0.7767
s.e.	0.1031	0.0992	0.1180	0.1222

$\sigma^2 = 7182$: log likelihood = -607.04

AIC=1224.07 AICc=1224.69 BIC=1237.24

- comentar que os dois modelos ajustam bem, mas que pelo princípio da parcimônia, deve-se escolher o que tem menos parâmetros.

d. Apresente a equação do modelo selecionado.

- Utilize a estimativa dos parâmetros. Exemplo: o modelo selecionado é um AR(1) definido como $x_t = 0.5x_{t-1} + \epsilon_t$, $t = 1, 2, 3, \dots$, em que $\{\epsilon_t\}$ é um processo i.i.d. $\text{Normal}(0, 3)$;

e. No final do relatório, inclua como um apêndice o código do R que foi utilizado.

- copia o código com `echo=T` no fim